TP3 — Perceptrón Simple y Multicapa

Sistemas de Inteligencia Artificial — ITBA 2026

Equipo SIA

Marco teórico y objetivos

Objetivos del TP3

- **Ejercicio 1**: Estudio de fraude online con perceptrón simple lineal vs no lineal (knowledge distillation de *BigModel*).
- **Ejercicio 2**: Clasificación de dígitos con MLP, variando tasa de aprendizaje, arquitectura y mecanismo de optimización.
- **Ejercicio 3**: Mejorar el clasificador con `more_digits.csv` buscando **accuracy** $\geq 98\,\%$.

Esta presentación se centra en **EJ2 y EJ3**.

Arquitectura del MLP (Clase 11, Clase 13 - Backprop)

Forward: $V_j^m = \theta\left(\sum_k V_k^{m-1} \cdot w_{jk}^m\right)$ con $V^0 = x$, $O = V^M$.

Loss (MSE): $E(w) = \frac{1}{2N} \sum_{\mu=1}^{N} \sum_i \left(\zeta_i^\mu - O_i^\mu\right)^2$

Backward (regla de la cadena):

$$\delta^{(L)} = (O - t) \odot f'(h^{(L)}), \quad \delta^{(m)} = \left(W^{(m+1)\top} \delta^{(m+1)}\right) \odot f'(h^{(m)})$$

$$\frac{\partial E}{\partial W^{(m)}} = \frac{1}{N} \delta^{(m)} V^{(m-1)\top}, \quad w^{\text{nuevo}} = w^{\text{ant}} - \eta \frac{\partial E}{\partial w}$$

Capacidad y generalización (Clase 13 - Regularización): más capacidad $\Rightarrow$ más riesgo de overfitting; brecha train−validación crece con la capacidad.

EJ2 — Clasificación de dígitos

Contexto del ejercicio

Problema: CompanyX necesita un sistema automático para clasificar dígitos escritos a mano (0–9) a partir de imágenes de 28×28 pixels.

Modelo: Perceptrón Multicapa (MLP) con salida de 10 neuronas (una por dígito), entrenado con MSE.

Estrategia experimental:

1. Ver dependencia entre batch size y learning rate
2. Ver variación de accuracy según optimizador y learning rate
3. Explorar arquitecturas: ¿más capas o más nodos por capa?
4. Evaluar funciones de activación en capas ocultas
5. Analizar el mejor modelo sobre el conjunto de test

División: 80 % train / 20 % val (estratificado) sobre `digits.csv`; `digits_test.csv` como "mundo real".

Análisis del dataset — Distribución de clases

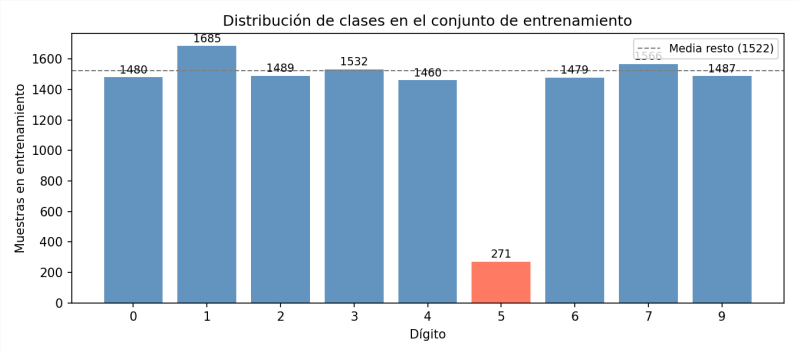

Distribución de muestras por dígito en el conjunto de entrenamiento. Se observa una marcada subrepresentación del 5 y la ausencia total del 8.

Análisis del dataset — Observaciones e hipótesis

Dataset / clase	0	1	2	3	4	5	6	7	8	9
Train (12 449)	1480	1685	1489	1532	1460	**271**	1479	1566	**0**	1487
Test (2 497)	245	283	258	252	245	223	239	257	**243**	252

Observaciones:

- El train **no contiene la clase 8** — el modelo nunca verá un ejemplo de ese dígito.
- La clase 5 tiene solo **271 muestras** ($\sim$2 % del train) contra $\sim$12 % para el resto.
- El test sí incluye 243 muestras del 8 ($\sim$10 % del test).

Hipótesis:

- El 8 será sistemáticamente mal clasificado (techo de test accuracy $\approx$ 90 %).
- El dígito 5 tendrá menor F1 por la escasez de muestras.

Exp1 — Parámetros iniciales

Parámetro	Valor
Arquitectura	[784, 40, 20, 10]
Activación oculta	tanh
Activación de salida	logistic
β (pendiente sigmoidea)	1.0
Inicialización	random_normal, init_scale=0.1
Optimizador	GD (gradiente descendente)
Épocas máximas	500
Función de pérdida	MSE
Early stopping	patience=50, $\varepsilon = 0{,}001$
Seeds	[0, 1, 2, 3, 4]

Valores por defecto; se varían batch size y learning rate en este experimento.

Exp1 — Batch size × learning rate

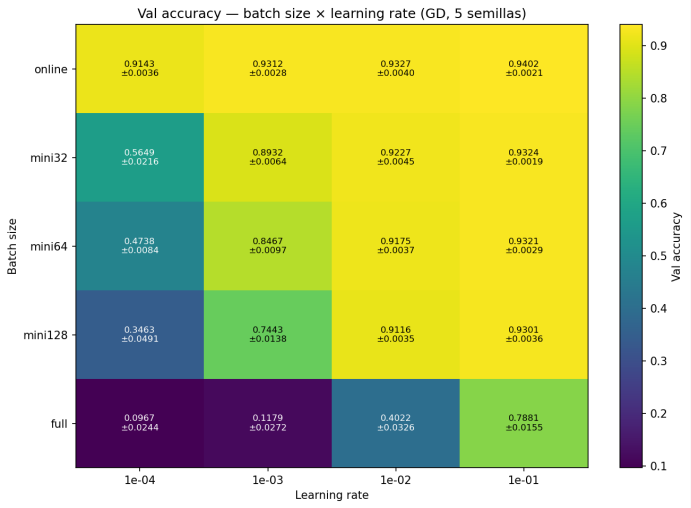

5 batch sizes × 5 learning rates × 5 seeds. La zona óptima se concentra en lr $\in [10^{-3}, 5{\cdot}10^{-3}]$ con batch $\in [8, 128]$.

Exp1 — ¿Online o mini-batch?

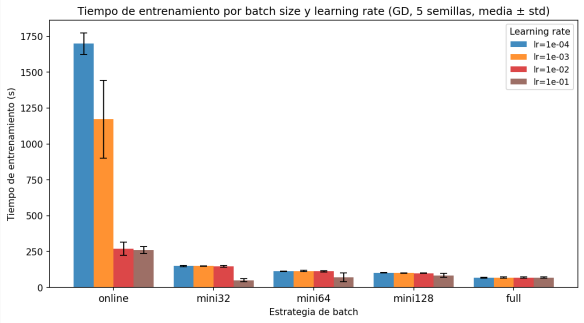

Hallazgos:

- El entrenamiento **online** (batch=1) logra la mejor val accuracy, pero es $\sim 10\times$ más lento.
- Mini-batch 32 y 64 obtienen resultados comparables con mucho menor tiempo de entrenamiento.
- El learning rate adecuado **depende del batch size**: batch grande necesita lr más alto; online necesita lr más bajo.

Decisión: batch size = **32**. Buen balance entre velocidad y accuracy; además permite flexibilidad en la elección de lr.

Exp2 — Parámetros iniciales

Parámetro	Valor
Arquitectura	[784, 40, 20, 10]
Activación oculta	tanh
Activación de salida	logistic
β (pendiente sigmoidea)	1.0
Inicialización	random_normal, init_scale=0.1
Batch size	32
Épocas máximas	500
Función de pérdida	MSE
Early stopping	patience=50, $\varepsilon = 0{,}001$
Seeds	[0, 1, 2, 3, 4]

Se varían optimizador y learning rate.

Exp2 — Convergencia: GD

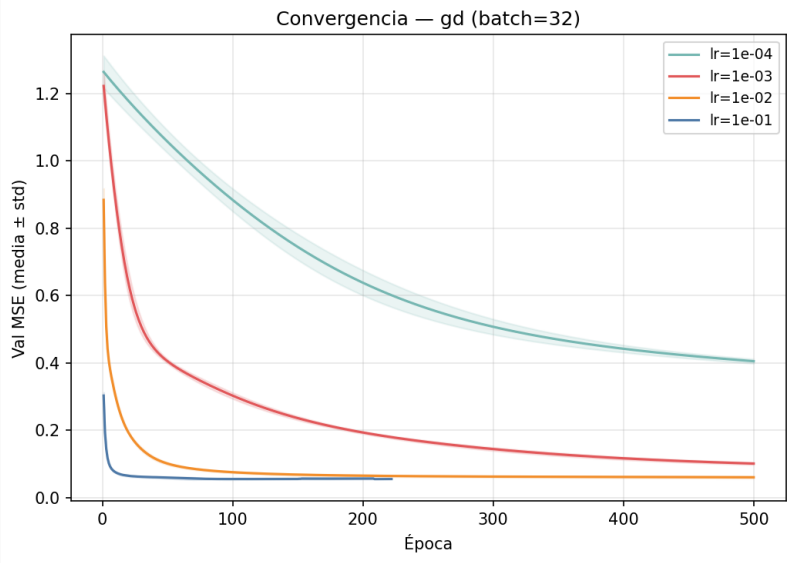

Exp2 — Convergencia: Momentum ($\alpha = 0{,}9$)

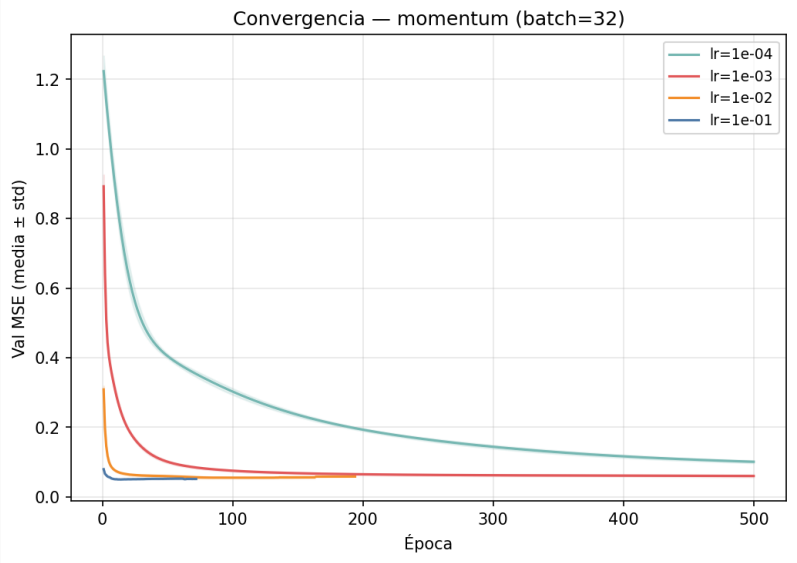

Exp2 — Convergencia: Adam (β_1=0,9, β_2=0,999, ε=10^{-8})

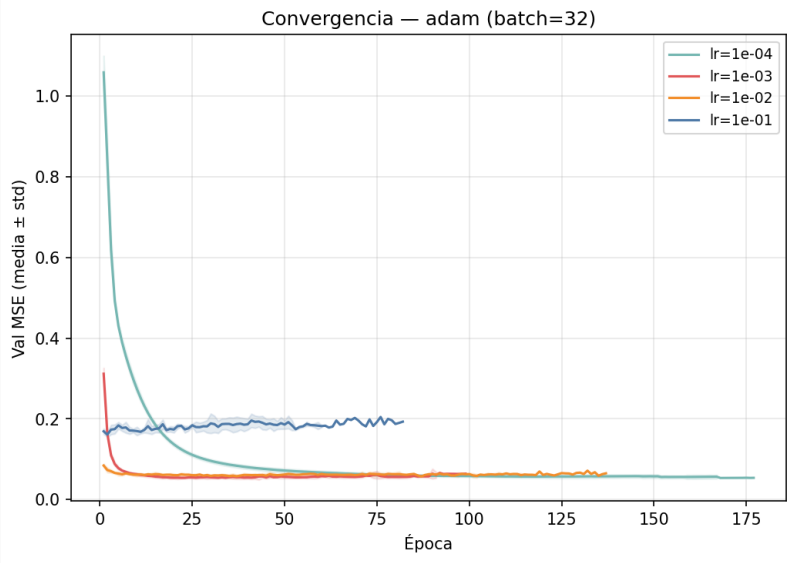

Exp2 — Cada optimizador tiene su learning rate óptimo

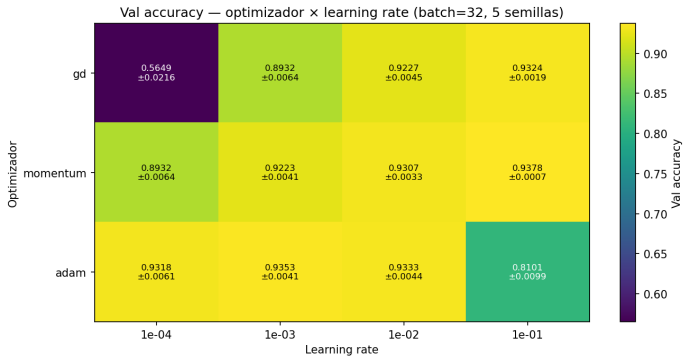

3 optimizadores × 4 learning rates × 5 seeds. GD necesita lr alto ($\sim$0.1), Momentum funciona en rango intermedio, Adam rinde mejor con lr $\sim 10^{-3}$.

Exp2 — ¿Por qué Adam con lr $= 10^{-3}$?

- **Adam** adapta la tasa de aprendizaje por parámetro (momentos de primer y segundo orden), por lo que trabaja bien con lr bajos y converge rápido.
- **GD** no tiene adaptación: necesita lr alto para moverse, pero eso genera inestabilidad.
- **Momentum** queda en un punto intermedio: acelera en direcciones consistentes pero no adapta por parámetro.
- Conclusión: **Adam con lr** $= 10^{-3}$ como optimizador base para los experimentos siguientes.

Exp3 — ¿Más capas o más nodos por capa?

Pregunta: dada una cantidad de parámetros, ¿es mejor distribuirlos en más capas (profundidad) o en más nodos por capa (anchura)?

Arquitecturas evaluadas:

- 1 capa oculta: [784, 32, 10], [784, 64, 10], [784, 128, 10], [784, 256, 10]
- 2 capas ocultas: [784, 40, 20, 10], [784, 64, 32, 10], [784, 64, 64, 10], [784, 128, 64, 10]
- 3 capas ocultas: [784, 64, 32, 16, 10], [784, 64, 64, 64, 10]

Configuración: Adam lr= 10^{-3}, batch=32, ReLU, 5 seeds, early stopping.

Resultados en desarrollo.

Exp3 — Resultados preliminares

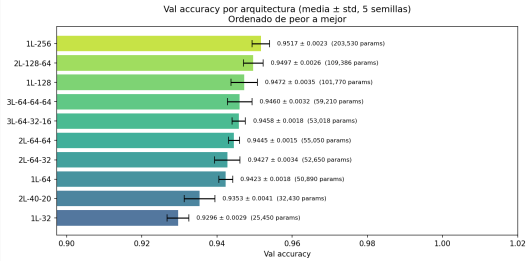

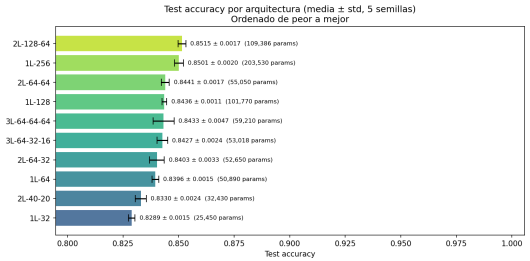

Tendencia: mayor capacidad mejora val accuracy pero aumenta el gap train–val (overfitting). 2 capas ocultas con suficientes nodos (128-64) logran el mejor balance.

Exp4 — Activaciones en capas ocultas

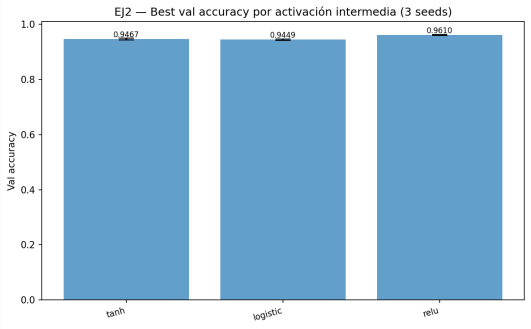

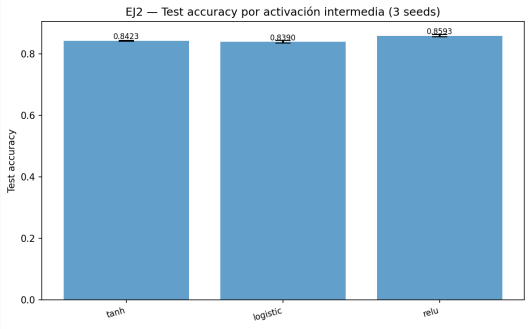

Arquitecturas [784, 256, 10] y [784, 128, 64, 10], Adam lr= 10^{-3}, batch=32. Tres funciones de activación evaluadas: **logistic**, **tanh** y **ReLU**.

Exp4 — Convergencia por activación

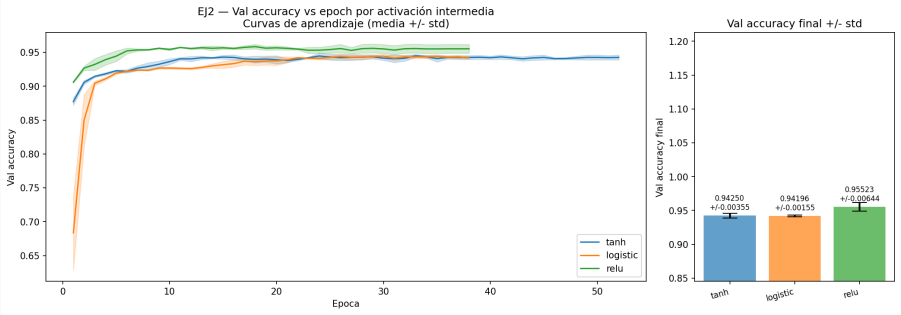

ReLU converge más rápido y alcanza la mejor val accuracy. Logistic sufre de saturación (derivada pequeña) y converge más lento.

Exp4 — Conclusión: elección de activación

Activación	Arquitectura	Val accuracy	Test accuracy
ReLU	[784, 128, 64, 10]	$0{,}9616 \pm 0{,}003$	$0{,}8640 \pm 0{,}002$
Tanh	[784, 128, 64, 10]	$0{,}9497 \pm 0{,}003$	$0{,}8515 \pm 0{,}002$
Logistic	[784, 128, 64, 10]	$0{,}9485 \pm 0{,}004$	$0{,}8467 \pm 0{,}002$

- Las tres funciones de activación dan resultados aceptables.
- **ReLU** es superior: no satura para valores positivos y propaga gradientes más eficazmente.
- **Logistic** es la más lenta en convergencia (derivada pequeña en saturación).
- Decisión: usamos **ReLU** como activación por defecto para los experimentos siguientes.

Exp5 — Configuración del mejor modelo

- **Arquitectura**: [784, 128, 64, 10] (109 386 parámetros)
- **Optimizador**: Adam ($\eta = 10^{-3}$, $\beta_1 = 0{,}9$, $\beta_2 = 0{,}999$, $\varepsilon = 10^{-8}$)
- **Batch size**: 32, init_scale=0.1
- **Activación oculta**: ReLU
- 5 seeds, hasta 150 epochs con early stopping (patience=20)

Resultados (5 seeds, mean $\pm$ std):

- Val accuracy: $0{,}9616 \pm 0{,}0028$
- Test accuracy: $0{,}8640 \pm 0{,}0017$
- Macro F1: $0{,}8176 \pm 0{,}0017$

Exp5 — Curvas de aprendizaje (5 seeds)

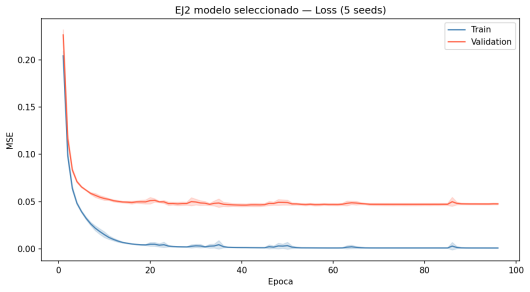

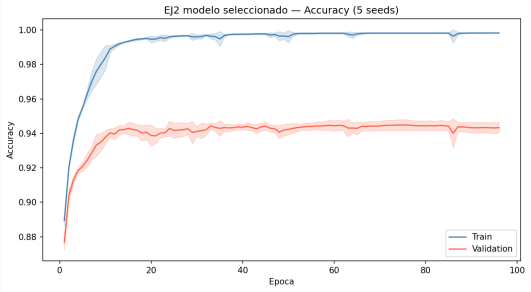

Exp5 — Matriz de confusión (test, promedio 5 seeds)

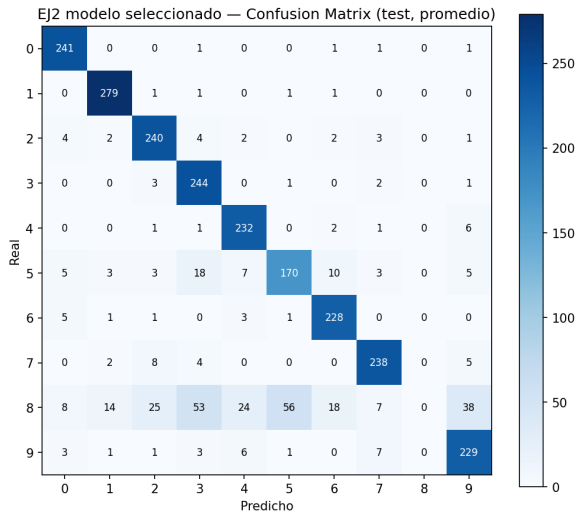

La fila del 8 es toda incorrecta: el modelo nunca vio un 8. Se confunde principalmente con 5 (23 %) y 3 (22 %).

Exp5 — Métricas por clase (test)

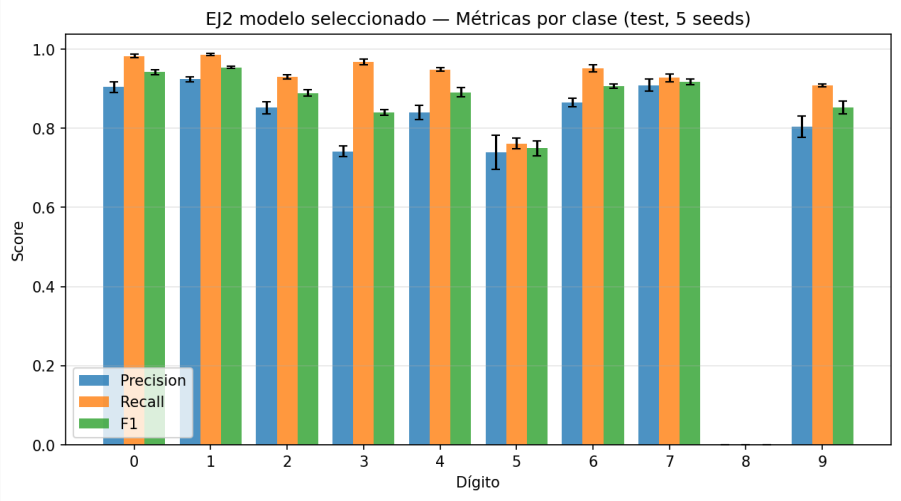

F1 del dígito 8 = 0.000 (ausente en train). El dígito 5 (271 muestras) también tiene F1 bajo ($\sim$0.75). Demás dígitos: F1 $\geq$ 0.84.

Exp5 — Análisis de confusiones por dígito (test)

Real	Acc clase	Top-1 confusión	Top-2 confusión
0	0.984	→3: 0.4 %	→6: 0.4 %
1	0.986	→2: 0.4 %	→3: 0.4 %
2	0.930	→0: 1.6 %	→3: 1.6 %
3	0.972	→2: 1.2 %	→7: 0.8 %
4	0.955	→9: 2.5 %	→6: 0.8 %
5	**0.759**	**→3: 8.0 %**	**→6: 4.5 %**
6	0.954	→0: 2.1 %	→4: 1.3 %
7	0.926	→2: 3.1 %	→9: 1.9 %
8	**0.000**	**→5: 23.0 %**	**→3: 21.8 %**
9	0.912	→7: 2.8 %	→4: 2.4 %

El 8, ausente del train, se reparte entre 5 (23 %) y 3 (22 %) — el modelo "los manda a cualquier lado". El 5, con solo 271 muestras en train, es la clase peor aprendida.

EJ3 — Mejor accuracy con `more_digits.csv`

Setup del EJ3

Cambio principal: el train pasa a ser `more_digits.csv` ($\sim$15.7k muestras, **10 clases incluyendo el 8**).

Test: el mismo `digits_test.csv` del EJ2 (mundo real) $\Rightarrow$ comparación directa con EJ2.

Objetivo: accuracy $\geq 98\,\%$ en test.

Técnicas adoptadas:

- Arquitectura más grande: $[784, 256, 128, 10]$ (235,146 params).
- Más epochs (150) + patience (20).
- Weight decay liviano ($\lambda = 10^{-5}$) — regularización L2 (Clase 13 - Regularización).
- Init scale más chico (0.05) para mejor estabilidad.
- Batch size 64 (más grande $\Rightarrow$ menos varianza por step).

Comparación de datasets (*aislando el efecto de los datos*)

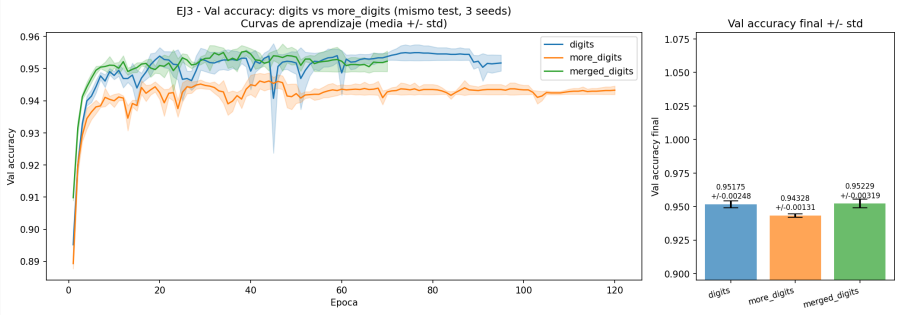

Misma arquitectura $[784, 128, 64, 10]$, mismo test, sólo cambia el train.

Test accuracy: digits vs more_digits

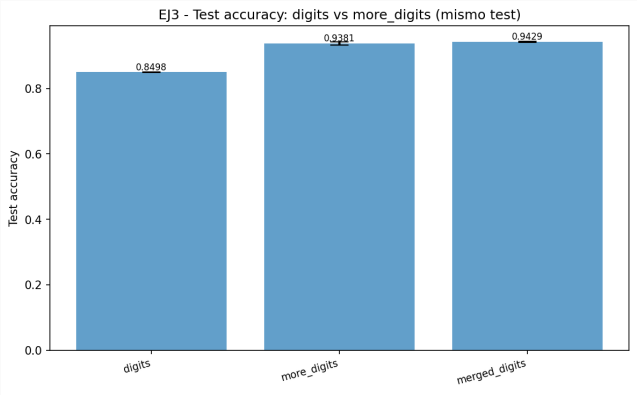

Salto de $\sim$80 % a $>$95 % sólo por incluir la clase 8 en train y tener $\sim$26 % más datos.

F1 por clase (test): digits vs more_digits

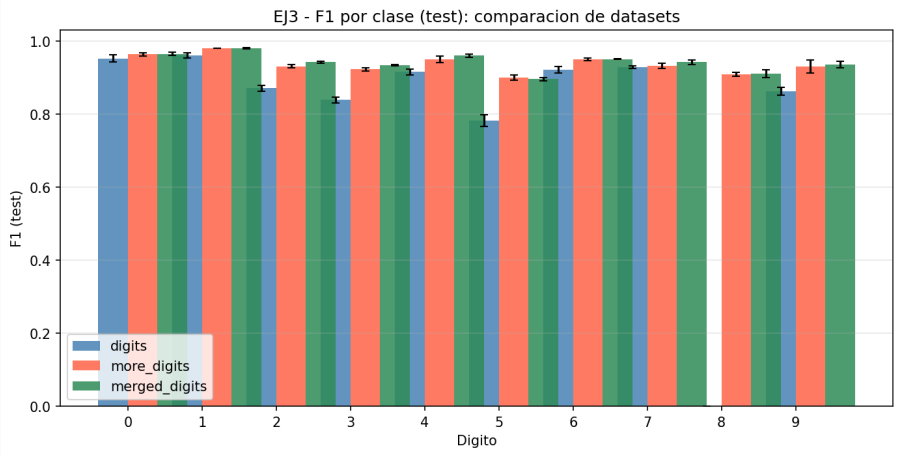

El dígito 8 pasa de F1=0 (no se entrena) a $\sim$0.95.

EJ3 modelo seleccionado — accuracy curves

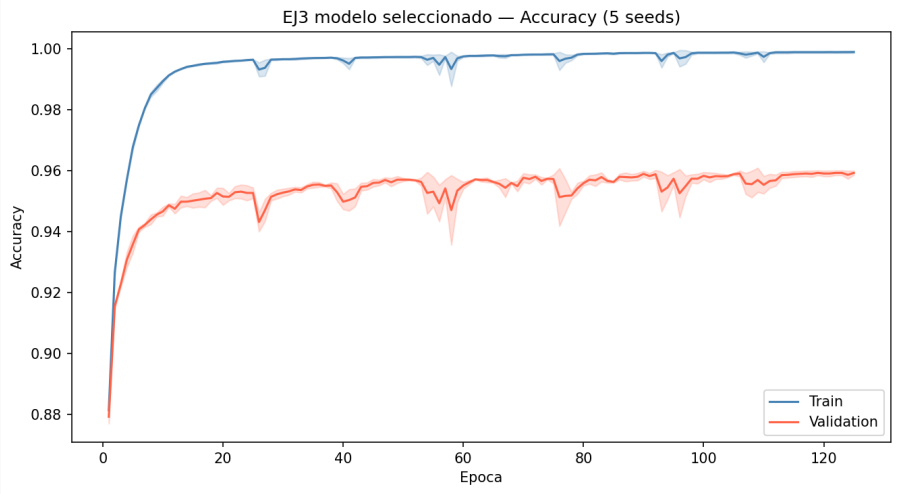

EJ3 — Confusion matrix (test, promedio sobre 5 seeds)

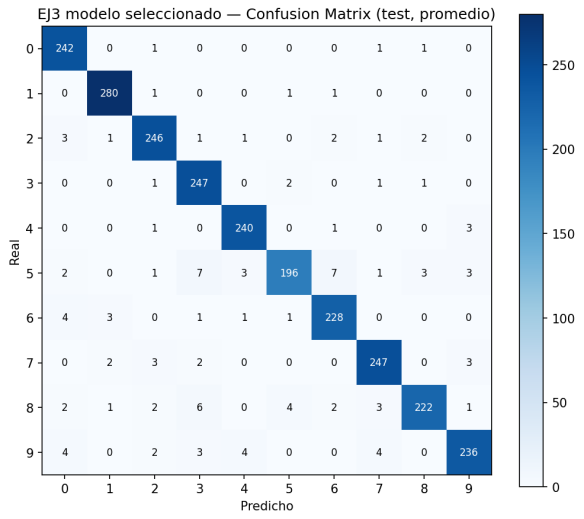

EJ3 — Métricas por clase

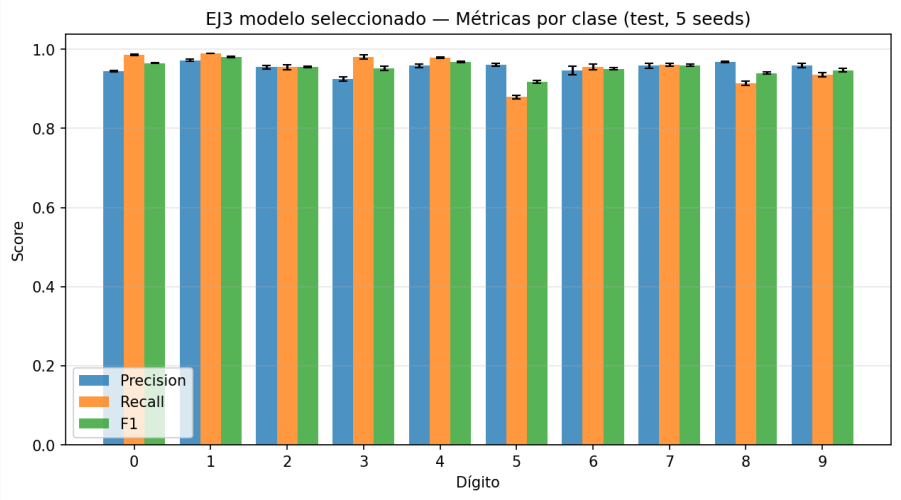

EJ3 — Análisis de confusiones por dígito (test)

Real	Acc clase	Top-1 confusión	Top-2 confusión
0	0.988	→2: 0.4 %	→7: 0.4 %
1	0.989	→2: 0.4 %	→5: 0.4 %
2	0.957	→0: 1.2 %	→6: 0.8 %
3	0.980	→5: 0.8 %	→2: 0.4 %
4	0.980	→9: 1.2 %	→2: 0.4 %
5	0.879	→3: 3.1 %	→6: 3.1 %
6	0.958	→0: 1.7 %	→1: 1.3 %
7	0.961	→2: 1.2 %	→9: 1.2 %
8	**0.914**	**→3: 2.5 %**	**→5: 1.6 %**
9	0.933	→0: 1.6 %	→4: 1.6 %

El 8 pasa de acc=0.000 (EJ2) a 0.914 (EJ3) — confirma el efecto de incluirlo en el train. Las confusiones residuales del 5 y 8 son con 3, 5, 6 — patrón consistente con similitud visual.

EJ3 — Resultados finales y discusión del 98 %

Mejor resultado obtenido (3 seeds):

- Test accuracy: $0{,}9546 \pm 0{,}0007$ (95.5 %)
- Val accuracy: $0{,}9603 \pm 0{,}0001$
- Macro F1: 0,9536 (vs 0,7942 en EJ2)
- F1 mínimo (dígito 5): 0,918 (vs 0,749 en EJ2)

No alcanzamos 98 % en test. Lo que obtuvimos:

- Train acc $\rightarrow$ 0.999 con val acc plateau en $\sim$0.96 (overfitting clásico, Clase 13 - Regularización).
- El gap train$-$val es de $\sim$0.04, indicando que la red está saturando en su capacidad de generalización con este pipeline.

Para llegar a 98 % se necesitarían: data augmentation (rotaciones, traslaciones — Clase 13), arquitecturas convolucionales, o ensembling. Quedó fuera del scope de un MLP básico.

Conclusiones

Conclusiones EJ2

- **Exp1 (batch $\times$ lr)**: el learning rate óptimo depende del batch size. Online logra la mejor accuracy pero es 10$\times$ más lento. Se elige batch=32 como compromiso eficiencia/rendimiento.
- **Exp2 (optimizadores)**: cada optimizador tiene su rango óptimo de lr. Adam con lr=10^{-3} domina en accuracy y velocidad.
- **Exp3 (arquitecturas)**: más capacidad mejora val accuracy pero aumenta el gap train–val. 2 capas ocultas con suficientes nodos ofrecen el mejor balance.
- **Exp4 (activación)**: ReLU, tanh y logistic dan resultados aceptables. ReLU es preferida por convergencia más rápida y sin saturación en valores positivos.
- **Exp5 (mejor modelo)**: [784, 128, 64, 10] + ReLU + Adam lr=10^{-3}, batch=32. Val acc $\sim$96 %, test acc $\sim$86 %.
- **Techo de test accuracy $\approx$ 90 %** por la ausencia del dígito 8 en train. El 8 se confunde con 5 y 3; el dígito 5 (271 muestras) también sufre.

Referencias al material

- Clase 9 — Optimización (GD, SGD, Momentum, Adam)
- Clase 11 — Perceptrón Multicapa (forward pass, T. Aprox. Universal)
- Clase 12 — Métricas y Sobreajuste (accuracy, F1, confusion matrix)
- Clase 13 — Backprop (regla de la cadena, δ por capa)
- Clase 13 — Regularización (early stopping, L2 weight decay)